


Normalformen

Zweiter Schritt der Zerlegung der Relation *Filmliste* basierend auf der FD :  
 Kino → Telefonnummer (Tel.)



# Abhängigkeitsbewahrung

- Idee: Alle FDs, die für die Relation  $R$  gelten, sollen *lokal* auf den Relationen  $R_1, \dots, R_n$  aus der Zerlegung überprüfbar sein.
- Die Projektion von  $F$  auf  $\alpha$  ( $F_\alpha$ ) ist die Menge von FDs aus  $F^+$  die nur Attribute aus  $\alpha$  enthalten:

$$F_\alpha = \{ \beta \rightarrow \gamma \in F^+ \mid \beta\gamma \subseteq \alpha \}$$

# Abhängigkeitsbewahrung

- Berechnung von FD Projektionen :

**Input:**  $F, \alpha$

**Output:**  $F_\alpha$

Erg =  $\emptyset$

For each  $\beta \subseteq \alpha$  do

$T = \beta^+$  (bzgl.  $F$ )

    Erg = Erg  $\cup \{ \beta \rightarrow T \cap \alpha \}$

Return Erg

# Hüllentreue Zerlegung


- **Definition.**

Die Zerlegung der Relation  $R$  in Relationen  $R_1, \dots, R_n$  wird als hüllentreue Zerlegung bezeichnet falls:

$$F_R^+ = (F_{R_1} \cup \dots \cup F_{R_n})^+$$

- Intuitiv, müssen  $F_{R_1} \cup \dots \cup F_{R_n}$  und  $F_R$  äquivalent sein

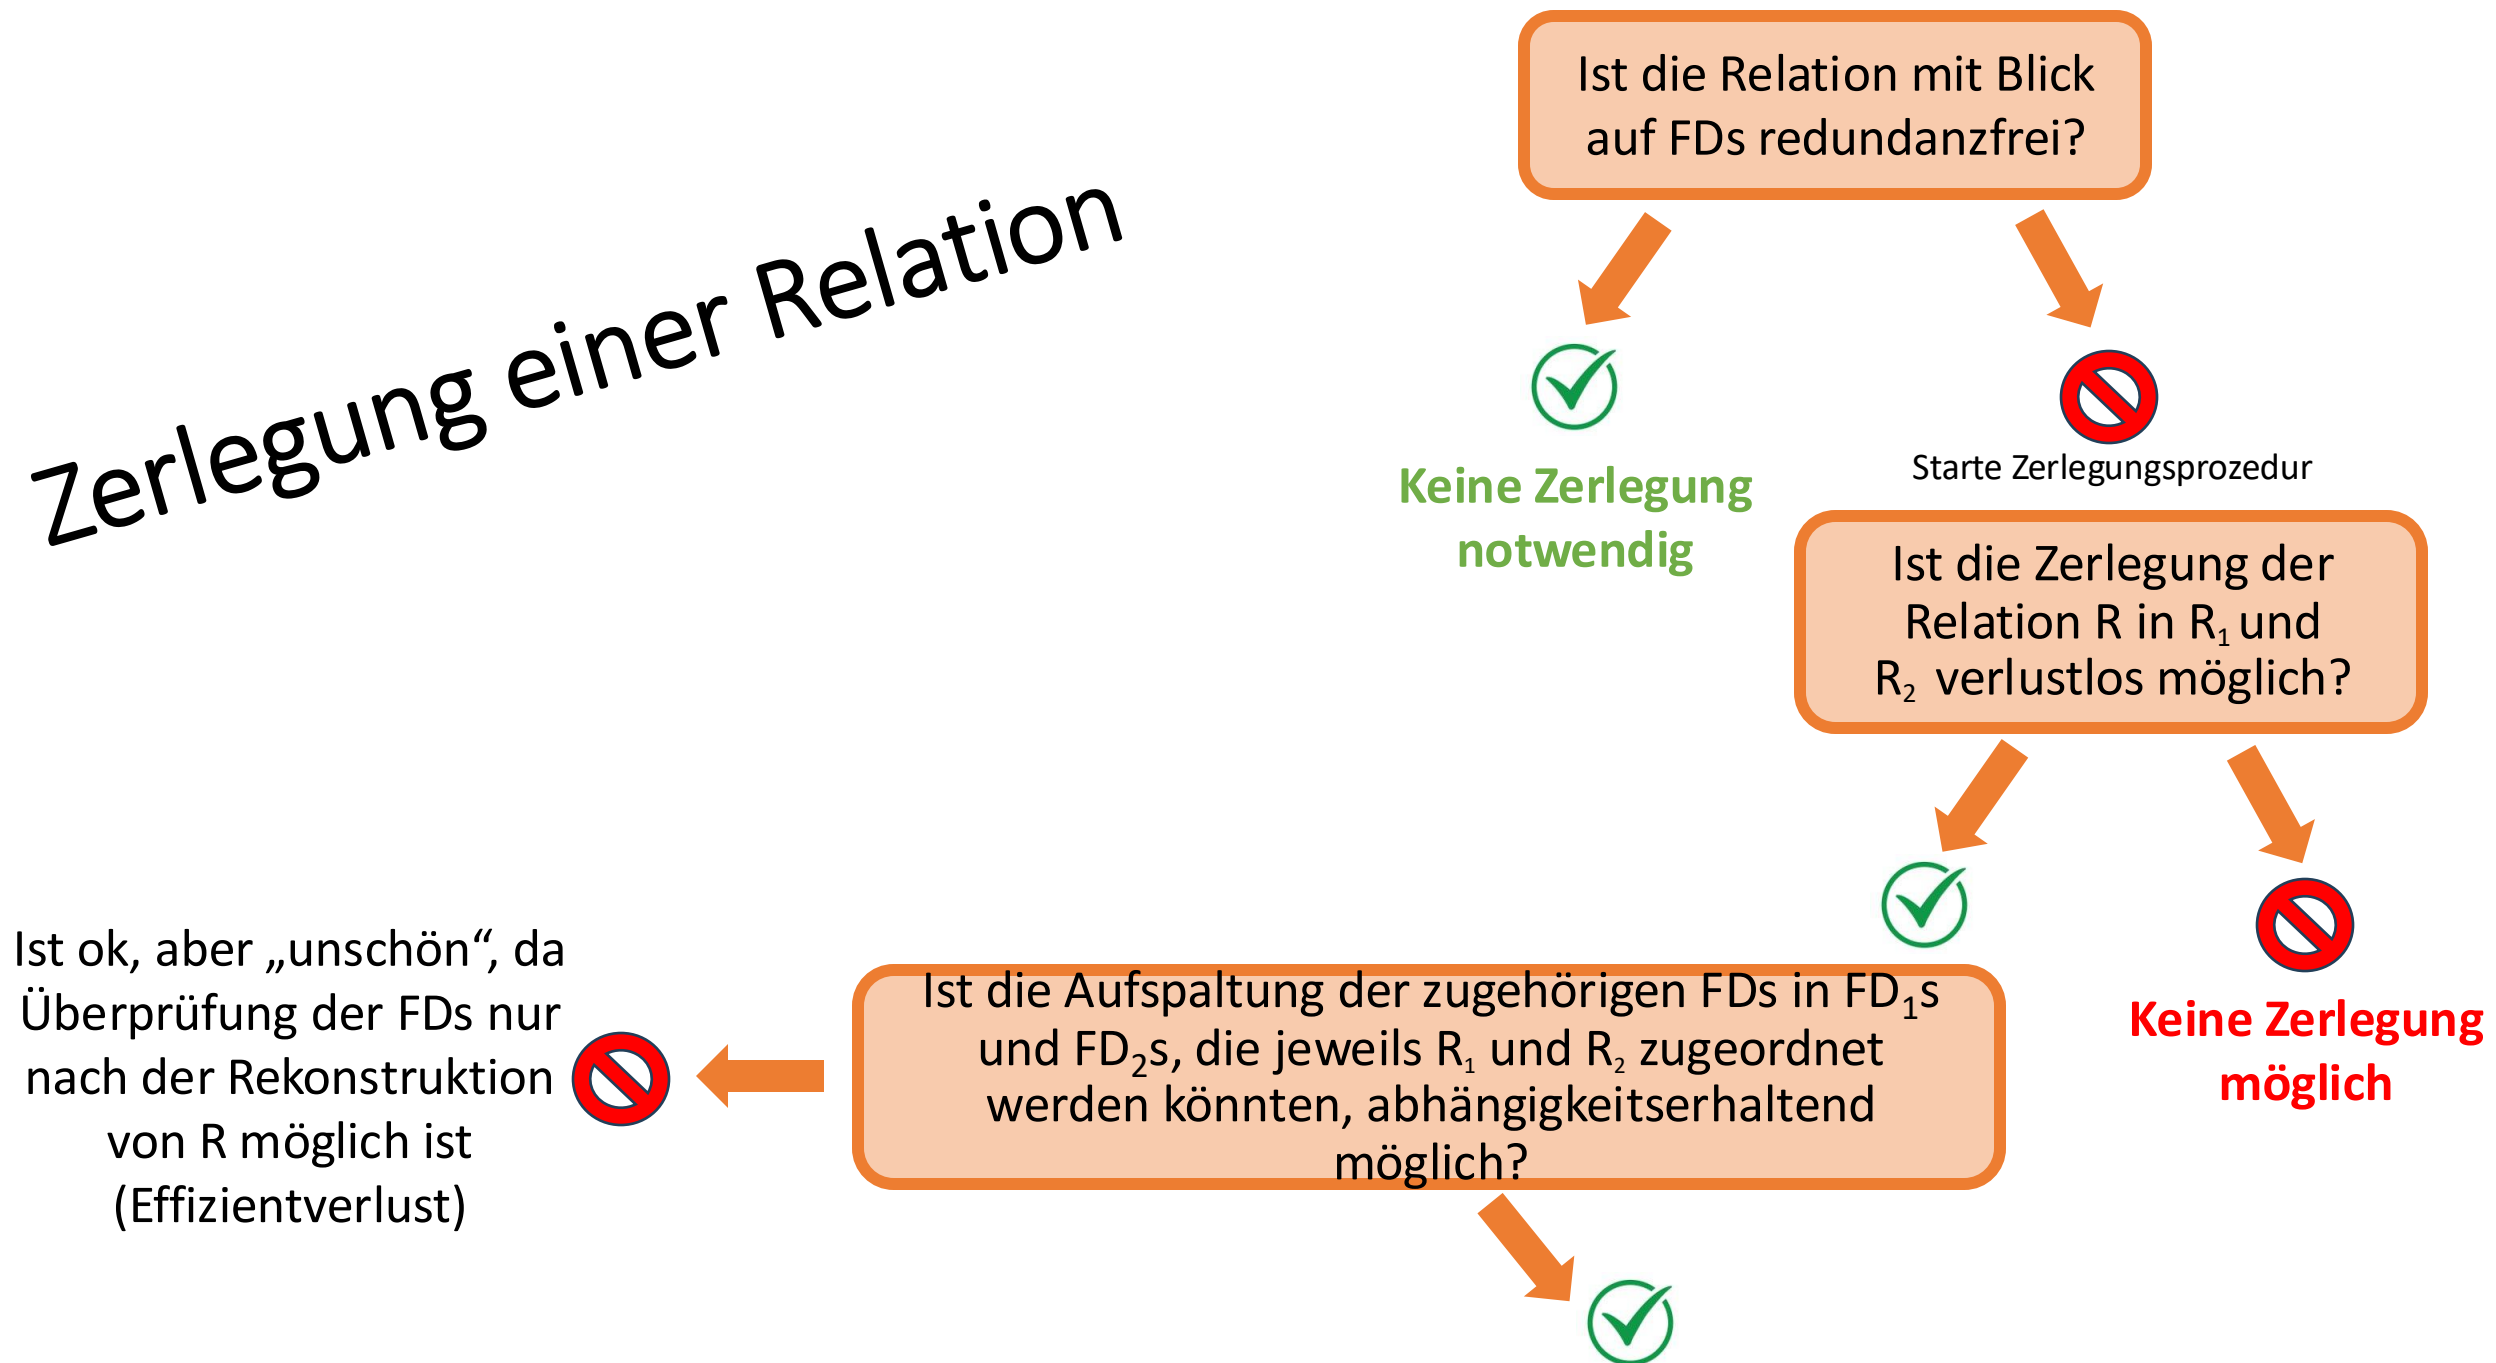
# Zerlegungbeispiel



Fun fact: In Deutschland  
gibt es über 2000  
Goethestraßen!

- PlzVerzeichnis(Straße, Ort, BLand, PLZ)
- Bedingungen:
  - Orte werden durch *Ort* und *BLand* eindeutig charakterisiert
  - Innerhalb einer Straße ändert sich *PLZ* nicht
  - PLZ-Gebiete gehen nicht über Ortsgrenzen, Orte nicht über Bundeslandgrenzen
- FDs:  $\{PLZ\} \rightarrow \{Ort, BLand\}$  und  $\{Straße, Ort, BLand\} \rightarrow \{PLZ\}$
- Die Zerlegung  $\{PLZ, Straße\}$  und  $\{PLZ, Ort, BLand\}$  ist:
  - Verlustlos (Corollary)
  - Nicht abhängigkeiterhaltend (die zweite FD ist *lokal* nicht überprüfbar)

# Zerlegung einer Relation



# Normalisierung

- Normalformen definieren Qualitätskriterien (Vermeiden von Inkonsistenzen)
  - Redundanz ist oft die Ursache von Schemaproblemen (keine FDs, keine Redundanz)
  - Normalisierung:
    - Jede Relation entspricht genau einer Objektmenge oder genau einer Relationship-Menge zwischen Objekten
    - Alle Informationen und Integritätsbedingungen (Schlüsselkandidaten und Fremdschlüssel) sind abgebildet
    - Redundanz ist weitgehend eliminiert
    - Es treten keine Änderungsanomalien auf
- ⇒ **Beseitigung von Abhängigkeiten innerhalb der Relation**



# Normalisierung

- Integritätsregeln, insbesondere FDs, helfen ein schlechtes Schema zu identifizieren
- Die Lösung ist meistens die Zerlegung der Relation
- **Fragestellung:** wann ist eine Zerlegung möglich, und wann ist sie notwendig?

# Normalformen

- Wenn eine Relation in einer Normalform ist, dann wissen wir, dass bestimmte Probleme nicht vorkommen können.
- Es hilft, um zu bestimmen ob eine Zerlegung weiter hilft oder nicht.
- Die Normalformen basierend auf FDs: 1NF, 2NF, 3NF, BCNF

$$\mathbf{BCNF \subseteq 3NF \subseteq 2NF \subseteq 1NF}$$

# 1. Normalform

- **Definition.** Eine Relation ist in der ersten Normalform, wenn alle Attribute der Relation **atomar** sind. Zusammengesetzte und mehrwertige Attribute sind nicht erlaubt.
- Nicht atomar: Dictionaries, Listen, Untertabellen, json- o.ä. Strukturen, usw
- Ist bei der benutzten Definition des relationalen Modells normalerweise automatisch eingehalten
- Atomar: String, Integer, etc.
- Bemerkung: Datum / Uhrzeit wird als atomar betrachtet
- Was ist atomar genug?
  - (Name, Vorname) oder (Name und Vorname)
  - (Jahr, Monat, Tag, Stunde, Minute, Sekunde) oder (Timestamp)

# Relation nicht in 1NF

Kunden (KundenID, Name, Vorname, Produkte)



Transformation in 1NF durch Zerlegung

<u>KundenID</u>	Name	Vorname	Produkte
K1	Nuhr	Dieter	Asus
K2	Pelzig	Erwin	iPhone, iPad, Vaio
K3	Gruber	Monika	Nexus, Galaxy Tab, Kindle

Kunden (KundenID, Name, Vorname )

Bestellung ( KundenID, Produkt )

Referenzielle Integritätsbedingung (Fremdschlüssel):

Bestellung.KundenID referenziert Kunden.KundenID

<u>KundenId</u>	Name	Vorname
K1	Nuhr	Dieter
K2	Pelzig	Erwin
K3	Gruber	Monika

<u>KundenID</u>	<u>Produkt</u>
K1	Asus
K2	iPhone
K2	iPad
K2	Vaio
K3	Nexus
K3	Galaxy Tab
K3	Kindle

## 2. Normalform

- **Definition.** Eine Relation  $R$  mit zugehörigen FDs  $F$  ist in zweiter Normalform, genau dann wenn es in 1NF ist und **jedes Nichtschlüssel-Attribut**  $A \in R$  voll funktional abhängig ist von **jedem Kandidatenschlüssel** der Relation.
- Eine funktionale Abhängigkeit  $X \rightarrow Y$  heißt **voll**, wenn es keine echte Teilmengen  $Z \subset X$  gibt, s.d. gilt  $Z \rightarrow Y$
- Intuitiv: Ein Relationenschema verletzt 2NF, wenn in der Relation Informationen über mehr als ein einziges Konzept modelliert werden.
- Selbst bei Erfüllung der 2NF können immer noch Redundanzen im Schema enthalten sein (durch transitive Abhängigkeiten)

# 2NF - Beispiel


- StudentenBelegung (MatrNr, VorlNr, Name, Semester)
- Primärschlüssel: {MatrNr, VorlNr}
- FDs welche 2NF verletzen:
  - {MatrNr} → {Name}
  - {MatrNr} → {Semester}
- **Bemerkung.** Hier können wir auch die Anomalien wiedererkennen.
- Zerlegung:
  - Enrolled(MatrNr, VorlNr) - vllt. auch Note
  - Studenten(MatrNr, Name, Semester) - vllt. auch Email, Geburtsdatum, u.a.

# 3. Normalform

- **Definition.** Eine Relation mit zugehörigen FDs  $F$  ist in der 3. Normalform, wenn für alle Abhängigkeiten  $A \rightarrow B$  aus  $F^+$  gilt:
  - $B \subseteq A$  (FD ist trivial) **oder**
  - $A$  enthält einen Schlüssel von  $R$  ( $A$  ist ein Superschlüssel) **oder**
  - $B$  ist Teil eines Schlüsselkandidaten ( $B$  ist prim)
- **Äquivalente Def.** Eine Relation  $R$  ist in 3NF, wenn sie in der 2NF ist und **kein Nichtschlüsselattribut von einem Schlüsselkandidaten** transitiv abhängt.
- **Bemerkung.** 3NF beseitigt Abhängigkeiten von Nicht-Schlüsselattributen.
- Selbst bei Erfüllung der 3NF sind Redundanzen möglich.
- Eine Relation bleibt in 3NF, wenn BCNF nicht erreichbar ist (keine gute Zerlegung oder aus Leistungsgründen)

# Relation nicht in 3NF

- Kurs (KursID, Titel, DozentName, Raum) - nicht in 3NF
- Es gilt: {DozentName} → {Raum}
- **Aber:** Dozentname ist kein Schlüssel und Raum ist nicht Teil eines Schlüsselkandidaten
- Folgende Anomalien können auftreten:
  - Dozenten und Raum sind ohne Zuordnung eines Kurses nicht verfügbar
  - Falls ein Dozent keinen Kurs liest, werden alle Informationen über den Dozenten und seinem Raum gelöscht
- Schema in 3NF:  
Kurs (KursID, Titel, DozentName)  
Dozent (DozentName, Raum)





# Boyce-Codd Normalform

- **Definition.** Eine Relation  $R$  mit zugehörigen FDs  $F$  ist in der Boyce-Codd Normalform, wenn für alle Abhängigkeiten  $A \rightarrow B$  aus  $F^+$  gilt:
  - $B \subseteq A$  (FD ist trivial) **oder**
  - $A$  enthält einen Schlüssel von  $R$  ( $A$  ist ein Superschlüssel)
- Die BCNF hat also außer den trivialen nur noch funktionalen Abhängigkeiten deren Determinante (linke Seite) ein Superschlüssel ist
- **Bemerkung.** Wenn  $R$  in BCNF ist, ist es automatisch auch in 3NF

# Relation in 3NF aber nicht BCNF


- Städte (*Ort, BLand, Ministerpräsident, Einw*)
- Schlüsselkandidaten:
  - (*Ort, BLand*)
  - (*Ort, Ministerpräsident*)
- FDs:
  - $BLand \rightarrow Ministerpräsident$
  - $\{Ort, BLand\} \rightarrow Einw$
  - $Ministerpräsident \rightarrow BLand$
- Relation ist in **3NF**, aber **nicht** in **BCNF**
- Anomalien können auftreten, da die Information, wer welches Bundesland regiert, mehrfach abgespeichert wird

# Normalformen - Übersicht


- 1. Normalform (1NF)
  - Keine mehrwertigen Attribute
- 2. Normalform (2NF)
  - Keine Vermischung von Sachverhalten in Relationen
- 3. Normalform (3NF)
  - Keine funktionalen Abhängigkeiten von Nichtschlüsselattributen innerhalb von Relationen
- Boyce-Codd-Normalform (BCNF)
- Weitere Normalformen
  - 4. Normalform (4NF)
  - 5. Normalform (5NF)

# Normalformen - Zusammenfassung


**1NF** – alle Attribute sind atomar




**2NF** – alle Nichtschlüsselattribute sind voll funktional abhängig von jedem Kandidatenschlüssel (keine partiellen Abhängigkeiten)



**3NF** – in 2NF und alle Nichtschlüsselattribute sind nur von Kandidatenschlüssel abhängig (keine transitiven Abhängigkeiten)



**BCNF** – jede Determinante ist ein Superschlüssel (alle FDs werden von Kandidatenschlüsseln bestimmt)



# 3NF vs. BCNF

- **Bemerkung.** Man kann jede Relation  $R$  so in  $R_1, \dots, R_n$  zerlegen, dass gilt:
  - Die Zerlegung ist **verlustlos** und **abhängigkeitsbewahrend**
  - $R_i$  ist in **3NF**,  $1 \leq i \leq n$
- **Bemerkung.** Man kann jede Relation  $R$  so in  $R_1, \dots, R_n$  zerlegen, dass gilt:
  - Die Zerlegung ist **verlustlos**
  - $R_i$  ist in **BCNF**,  $1 \leq i \leq n$
- Aber man kann nicht immer eine BCNF-Zerlegung finden, die auch abhängigkeitsbewahrend ist.

# BCNF-Zerlegung

- Wenn die funktionale Abhängigkeit  $\alpha \rightarrow \beta$  die BCNF verletzt, dann können wir die Relation in  $R - \beta$  und  $\alpha \cup \beta$  zerlegen. Wir können das weitermachen bis alle neuen Relation in BCNF sind (es geht immer zu Ende) (Zerlegung Korollar).
- Diese Zerlegung wird verlustlos, aber nicht unbedingt abhängigkeitsbewahrend sein
- **Bem.** Wenn es mehrere Abhängigkeiten gibt welche die BCNF verletzen, dann macht es einen Unterschied welche wir als erste für die Zerlegung auswählen.

# BCNF – Zerlegungsbeispiel

- $R(\underline{C}, S, J, D, P, Q, V)$
- $F = \{ JP \rightarrow C, \quad SD \rightarrow P, \quad J \rightarrow S \}$
- $SD \rightarrow P$  verletzt BCNF  $\Rightarrow$  Zerlegung  $(\underline{S}, \underline{D}, P)$  mit  $F_1 = \{SD \rightarrow P\}$  und  $(\underline{C}, S, J, D, Q, V)$  mit  $F_2 = \{J \rightarrow S\}$
- $J \rightarrow S$  verletzt BCNF für die zweite Relation  $\Rightarrow (\underline{C}, S, J, D, Q, V)$  wird in  $(\underline{J}, S)$  und  $(\underline{C}, J, D, Q, V)$  zerlegt
- D.h.  $R$  wird in  $(\underline{S}, \underline{D}, P)$ ,  $(\underline{J}, S)$  und  $(\underline{C}, J, D, Q, V)$  zerlegt – verlustlos, aber nicht abhängigkeitsbewahrend

# Kanonische Überdeckung

- **Definition (Äquivalenz funktionaler Abhängigkeiten).**

Zwei Mengen  $F$  und  $G$  von FDs eines Relationenschemas  $R$  sind äquivalent, falls  $F^+ = G^+$  gilt.

- Wunsch: Berechne eine möglichst kleine Menge, die zu  $F$  äquivalent ist  $\rightarrow$  geringer Aufwand beim Testen, ob ein neues Tupel eine FD verletzt



# Kanonische Überdeckung

- Man kann **überflüssige Attribute** durch Links- und Rechtsreduktion entfernen:
- **Linksreduktion**
  - Führe für jede FD  $A \rightarrow B$  aus  $F$  die Linksreduktion durch, indem für alle  $X \in A$  überprüft wird ob das Attribut  $X$  überflüssig ist, d.h. ob gilt
$$B \subset \text{Hülle}(F, A - \{X\})$$
, also  $(A - \{X\})^+$  in Beziehung zu  $F$   
(anders gesagt  $(F - \{A \rightarrow B\} \cup \{(A - \{X\}) \rightarrow B\})^+ = F^+$ )  
Ist dies der Fall, ersetze  $A \rightarrow B$  durch  $A - \{X\} \rightarrow B$
- **Rechtsreduktion**
  - Führe für jede FD  $A \rightarrow B$  aus  $F$  die Rechtsreduktion durch, indem für alle  $Y \in B$  überprüft wird ob das Attribut  $Y$  überflüssig ist, d.h. ob gilt
$$Y \in \text{Hülle}(F - (A \rightarrow B) \cup (A \rightarrow B - \{Y\}), A)$$
  
(anders gesagt  $(F - \{A \rightarrow B\} \cup \{A \rightarrow (B - \{Y\})\})^+ = F^+$ )  
Ist dies der Fall, ersetze  $A \rightarrow B$  durch  $A \rightarrow B - \{Y\}$

# Kanonische Überdeckung

- **Definition (Kanonische Überdeckung).**

Die Menge von FDs  $F_c$  wird als **kanonische Überdeckung** von  $F$  bezeichnet, falls folgende Bedingungen erfüllt sind:

- $F_c^+ = F^+$  (Äquivalenz) (1)
- Für alle FDs  $A \rightarrow B$  in  $F_c$  gibt es keine überflüssigen Attribute in A und in B, d.h.
  - für alle Attribute C aus A gilt  $(F_c - \{A \rightarrow B\} \cup \{(A - \{C\}) \rightarrow B\})^+ \neq F^+$  (2)
  - für alle Attribute D aus B gilt  $(F_c - \{A \rightarrow B\} \cup \{A \rightarrow (B - \{D\})\})^+ \neq F^+$  (3)
  - jede linke Seite der FDs in  $F_c$  kommt nur einmal vor, d.h. Falls  $A \rightarrow B$  und  $A \rightarrow C$ , dann wird in  $F_c$  nur die FD  $A \rightarrow B \cup C$  verwendet (4)
- Intuitiv: (2) – keine überflüssigen Attribute auf der linken Seite von FDs  
(3) - keine überflüssigen Attribute auf der rechten Seite von FDs